

# Técnicas del procesamiento del habla - TSCDIA - 2024



**Integrantes:** Florencia Andrada, Federico Cordoba, Guadalupe Mendoza, Noelia Soto

**Modalidad:** Grupal

**Entrega:** Evidencia de Aprendizaje N° 2


[Enlace Colab](#)

[Enlace repositorio GitHub.](#)

## Punto 1: Impacto de la Normalización de Datos

**Métricas:** Al eliminar el StandardScaler, el accuracy promedio de validación cruzada del SVM bajó del 89.0% al 78.1%. Aunque el modelo sin escalado convergió en menos iteraciones y el tiempo de entrenamiento fue menor, la solución alcanzada resultó significativamente menos precisa.

**Explicación y Conclusión:** El modelo SVM con kernel RBF es altamente sensible a la escala de las variables debido a que define sus fronteras de separación mediante el cálculo de distancias geométricas. Al desactivar la normalización, las características con magnitudes intrínsecamente más grandes dominan las ecuaciones de distancia, distorsionando la construcción del hiperplano óptimo y anulando el peso de las variables más chicas. El uso de StandardScaler es indispensable para equilibrar el aporte de cada descriptor y optimizar la capacidad de clasificación del SVM.



## Punto 2: Análisis de Robustez

**Métricas:** Se evaluaron dos condiciones de ruido sobre el conjunto de prueba frente a la línea de base (*Baseline*):

- Ruido A (suave y generalizado: amplitud 0.2 x std en el 100% de las muestras): El SVM subió su accuracy de 84.38% a 87.50% (+3.12%) mientras que Random Forest cayó de **87.50% a 84.38%** (-3.12%).
- Ruido B (fuerte y localizado: amplitud 1.0 x std en el 20% de las muestras): Random Forest mantuvo intacto su **87.50%** (0.00%), mientras que el SVM cayó a **78.12%** (-6.25%).

| Modelo        | Baseline | Con ruido (A) | $\Delta$ (A) | Con ruido (B) | $\Delta$ (B) |
|---------------|----------|---------------|--------------|---------------|--------------|
| Random Forest | 87.50%   | 84.38%        | -3.12%       | 87.50%        | 0.00%        |
| SVM RBF       | 84.38%   | 87.50%        | +3.12%       | 78.12%        | -6.25%       |

**Explicación y Conclusión:** La resiliencia no es absoluta y depende directamente de la naturaleza de la perturbación. Ante degradaciones suaves y distribuidas (Ruido A), el SVM responde mejor gracias a que las fronteras continuas del kernel RBF amortiguan variaciones pequeñas en todas las variables sin desplazar los puntos fuera de su región. En cambio, Random Forest se ve afectado en las muestras cercanas a sus umbrales rígidos de decisión.

Ante corrupciones intensas y puntuales (Ruido B), Random Forest resulta inmune debido a que el voto mayoritario del ensamble neutraliza las alteraciones de esas pocas muestras aisladas, mientras que en el SVM el impacto de estos desplazamientos bruscos sobre la frontera es directo. En entornos reales de audio ambiental, donde predomina el ruido de fondo continuo y de baja amplitud (estática o viento), el comportamiento del SVM RBF resulta más adecuado.

### Punto 3: Selección de Características

**Métricas:** Mediante la herramienta SelectKBest se redujo la dimensionalidad del dataset de 86 variables originales a un subconjunto de 20 features. Tras re-entrenar el modelo Random Forest con esta selección, el accuracy no disminuyó, sino que experimentó una leve mejora, pasando del 87.50% (con 86 features) al 90.62% (con solo 20 features).

**Explicación y Conclusión:** El incremento en el desempeño confirma que una gran parte de los descriptores originales aportaba información redundante o ruido matemático que afectaba el entrenamiento. Al aplicar el filtro ANOVA ( $f_{\text{classif}}$ ), se aislaron de forma efectiva las variables con mayor relevancia estadística interclase, concentrando el poder predictivo en las medias ( $\mu$ ) y desviaciones estándar ( $\sigma$ ) de los coeficientes MFCC y espectrales. Estas características representan

el núcleo de la frecuencia, energía y variación temporal indispensable para discriminar correctamente las clases del dataset a un menor costo computacional.

Como conclusión final, este laboratorio permitió validar la importancia crítica de las etapas de preprocesamiento y selección de variables en el diseño de un pipeline de clasificación de audio ambiental. El desarrollo de los experimentos demostró que el rendimiento de un modelo no depende únicamente de su arquitectura matemática, sino de la estructura y consistencia de los datos de entrada.

Por un lado, se comprobó la sensibilidad geométrica de modelos como el SVM frente a la escala de las variables, donde la ausencia de normalización desploma la precisión debido a la disparidad en las magnitudes de los descriptores espectrales. Por otro lado, el análisis de robustez ante el ruido blanco evidenció que la resiliencia no es una propiedad absoluta del algoritmo, sino que está sujeta a la naturaleza de la perturbación: mientras que el SVM RBF tolera mejor las degradaciones suaves y distribuidas continuas (similares al ruido de fondo real), Random Forest responde con total inmunidad ante corrupciones intensas pero localizadas gracias al sistema de votación de su ensamble.

Finalmente, la compresión del espacio de características mediante herramientas de selección demostró que gran parte de la información temporal promediada en audio es redundante. Reducir el dataset a las 20 variables estadísticas más significativas de los MFCCs y coeficientes espectrales no solo resguardó la capacidad predictiva del modelo, sino que optimizó el desempeño general disminuyendo el costo computacional. En definitiva, el trabajo subraya la necesidad de balancear la ingeniería de características con la naturaleza del entorno acústico para construir clasificadores eficientes y estables.

## BITÁCORA EVIDENCIA 2 - EJE II

### Hallazgos Técnicos

- **Mejor modelo seleccionado:** RANDOM FOREST
- **Métrica CV (Validation Accuracy):** 92.20%  $\pm$  2.6%
- **Métrica Test (Holdout Accuracy):** 90.62%
- **Features más de mayor impacto:** F40\_ $\mu$ , F1\_ $\mu$ , F15\_ $\sigma$  (Valores medios de los coeficientes MFCC 12, 1 y 0 respectivamente).
- **Clase con mayor tasa de error:** sea rain (El clasificador presentó 2 falsos positivos al etiquetar muestras de la clase 'sea' como 'rain').

### Decisiones de Diseño y Parametrización

- Justificación de  $n\_mfcc=13$  y  $hop\_length=256$ : La selección de 13 coeficientes MFCC constituye el estándar óptimo en tareas de reconocimiento y clasificación de audio analógico. Esta configuración permite capturar de forma eficiente la envolvente espectral y las propiedades tímbricas de la señal sin introducir componentes de alta frecuencia que deriven en ruido o sobreajuste (fenómeno común cuando se utilizan parametrizaciones orientadas a la inteligibilidad del habla, como  $n\_mfcc=40$ ). Por su parte, un valor de  $hop\_length=256$  combinado con una tasa de muestreo de 16 kHz establece una ventana temporal de ~16 ms entre frames contiguos, garantizando una resolución matemática lo suficientemente fina para registrar transitorios rápidos en ruidos estocásticos sin comprometer la eficiencia computacional del pipeline.
- Estrategia de Crop Centrado vs. Padding: La implementación del *crop centrado* se fundamenta en la naturaleza del dataset ESC-50, donde los eventos acústicos de mayor relevancia e intensidad (como el estímulo impulsivo de un ladrido o ráfagas de viento) se localizan estadísticamente en la región media del registro de audio. El recorte simétrico desde el centro mitiga el riesgo de pérdida de información crítica, evitando los segmentos de atenuación (*fade-in / fade-out*) o silencios residuales característicos de los extremos de las grabaciones. El recurso de *padding* se restringe analíticamente como método de contingencia únicamente para señales cuya duración sea inferior al umbral objetivo de 3 segundos.

### Reflexión Crítica: Arquitecturas de ML aplicadas a Audio

- Análisis comparativo frente al procesamiento de voz humana: A diferencia del habla humana, las señales de audio ambiental carecen de estructuras fonéticas ortogonales o de formantes definidos por las cavidades del tracto

vocal. Los entornos acústicos analizados están compuestos por señal de naturaleza estocástica continua (lluvia, oleaje) o fuentes de tipo transitorio/impulsivo (fauna).

Esta divergencia estructural invalida el uso exclusivo de características cepstrales estáticas. Para modelar adecuadamente la signature del entorno, se vuelve mandatorio incorporar coeficientes dinámicos de primer y segundo orden (Deltas y Delta-Deltas) que capturen la evolución temporal de la energía espectral. Asimismo, descriptores de dominio físico como el Spectral Centroid (indicador del centro de masa del espectro o brillantez) y el Zero Crossing Rate (ZCR, tasa de cruce por cero) resultan críticos para discriminar la fricción de alta frecuencia propia de la lluvia frente a componentes con mayor periodicidad tonal.